

Report scientifico progetto Introduzione alla Data Science e al Pensiero Computazionale

a.a. 2025/2026

Gabriele Pio Girbino, Lorenzo Merlini

1 luglio 2026

Sommario

L'employee attrition rappresenta una delle sfide più complesse per i dipartimenti di Risorse Umane. Questo progetto mira ad analizzare un set di dati aziendali per identificare i fattori chiave che spingono i dipendenti alle dimissioni e a sviluppare modelli di Machine Learning per prevedere tale fenomeno. Attraverso un'analisi esplorativa e l'addestramento di tre modelli predittivi (Regressione Logistica, k-NN e Random Forest), si è evidenziato come il salario mensile, l'età e l'esperienza lavorativa siano i fattori determinanti per l'ipotetico abbandono.

Repository GitHub: <https://github.com/lorenzomerlini03/progetto-introduzione-alla-data-science-e-pensiero-computazionale>

Indice

1	Introduzione	3
2	Descrizione e comprensione del dataset	3
2.1	Domande e Ipotesi	3
2.2	Statistiche Descrittive	4
2.3	Riflessioni Critiche sui Dati	4
3	Analisi Esplorativa e Visualizzazione	4
4	Modellazione	6
4.1	Preparazione del Dataset per la Modellazione	6
4.2	Regressione Logistica	6
4.3	K-Nearest Neighbors (k-NN)	6
4.4	Random Forest	6
5	Risultati e Discussione	6
5.1	Confronto dei Modelli	6
5.2	Spiegazione delle Metriche	7
5.3	Approfondimenti sui Modelli	7
6	Conclusioni	7

1 Introduzione

Il mantenimento dei dipendenti all'interno di un'azienda è fondamentale per garantire la continuità produttiva e ridurre i costi legati alla selezione e formazione di nuovo personale. L'obiettivo di questo elaborato è applicare i principi della Data Science per analizzare un dataset e prevedere l'abbandono dei dipendenti. Il documento è strutturato partendo dal controllo preliminare e dalle statistiche del dataset (Sezione 2), passando per l'analisi visiva (Sezione 3) e la modellazione (Sezione 4), per terminare con l'analisi dei risultati (Sezione 5) e le conclusioni (Sezione 6). L'analisi è stata svolta in Python con le librerie pandas [2], NumPy [3], matplotlib [4], seaborn [5] e scikit-learn [6].

2 Descrizione e comprensione del dataset

Il dataset analizzato è composto da 1470 dipendenti e 35 variabili, in cui la variabile target è *Attrition* (Yes/No).

2.1 Domande e Ipotesi

Interrogando il dataset, abbiamo testato 8 ipotesi specifiche, ottenendo i seguenti risultati numerici:

1. **Straordinari:** I dipendenti che fanno straordinari si dimettono in percentuale molto maggiore (30.5%) rispetto a chi non ne fa (10.4%).
2. **Età:** L'età influisce sull'abbandono. L'età media di chi ha lasciato l'azienda è di 33.6 anni, contro i 37.6 anni di chi è rimasto.
3. **Distanza:** La distanza casa-lavoro incide leggermente: chi si dimette percorre in media 10.6 km/miglia, contro gli 8.9 di chi resta.
4. **Stipendio:** Il reddito è un fattore critico. Lo stipendio medio mensile di chi ha lasciato è di 4787 dollari, contro i 6833 dollari di chi è rimasto.
5. **Soddisfazione:** Una soddisfazione lavorativa bassa (livelli 1-2) porta a un tasso di dimissioni del 19.7%, contro il 13.9% di chi ha un'alta soddisfazione (3-4).
6. **Promozioni:** Sorprendentemente, i dati smentiscono l'ipotesi dell'avanzamento di carriera: chi si è dimesso ha ricevuto una promozione in media più di recente (1.9 anni fa) rispetto a chi è rimasto (2.2 anni fa).
7. **Ruoli:** I ruoli con il maggior numero assoluto di dimissioni sono Laboratory Technician (62), Sales Executive (57) e Research Scientist (47).

8. **Anzianità:** Tra i dimessi figurano sia neoassunti (0 anni) sia i veterani con 40 anni di servizio, dimostrando che l'attrition colpisce tutte le fasce.

2.2 Statistiche Descrittive

Per comprendere la popolazione aziendale, abbiamo estratto 5 blocchi di statistiche descrittive:

1. **Profilo Demografico:** L'età media è 36.9 anni (min 18, max 60). Il 60% è uomo, il 40% donna. Il 45.8% è sposato, il 32.0% è single e il 22.2% è divorziato.
2. **Distribuzione Salariale:** Lo stipendio mensile medio è di 6503 dollari (mediana 4919 dollari), con estremi da 1009 a 19999 dollari.
3. **Condizioni di Lavoro:** Il 71% viaggia raramente, il 18.8% frequentemente e il 10.2% mai. Gli straordinari coinvolgono il 28.3% del personale.
4. **Struttura Aziendale:** L'anzianità media è di 7.0 anni. Il dipartimento più grande è Ricerca & Sviluppo (65.4%), seguito da Vendite (30.3%) e Risorse Umane (4.3%).
5. **Esperienza Precedente:** I dipendenti hanno in media 11.3 anni di esperienza totale e hanno lavorato per 2.7 aziende prima di questa, mentre il numero massimo di aziende precedenti per un singolo dipendente è 9.

2.3 Riflessioni Critiche sui Dati

L'esplorazione tecnica ha fatto emergere tre riflessioni strutturali fondamentali per il Machine Learning:

- **Sbilanciamento della variabile Attrition:** La classe target è fortemente sbilanciata (83.9% "No" contro 16.1% "Yes").
- **Feature sospette:** Variabili come ad esempio *EmployeeCount* e *Over18* contengono un solo valore per tutti e sono prive di varianza.
- **Formato testuale:** Ben 9 variabili oltre la variabile target sono in formato testuale, richiedendo una conversione numerica forzata.

3 Analisi Esplorativa e Visualizzazione

Per dare valore alle statistiche, abbiamo utilizzato strumenti di visualizzazione grafica che hanno messo in luce relazioni complesse tra le variabili e il target.

Un esempio evidente riguarda l'equilibrio tra vita privata e lavorativa (Figura 1). Utilizzando un Barplot percentuale, abbiamo scoperto che il tasso di abbandono arriva a superare il 30% tra i dipendenti che dichiarano un "Pessimo" Work-Life Balance (Livello 1).




Figura 1: Tasso di dimissioni in base all'equilibrio Vita-Lavoro.

Un'altra visualizzazione chiave è stata ottenuta tramite un Istogramma (Figura 2), che ha risolto il problema della sovrapposizione dei dati per isolare il fenomeno dei profili con meno esperienza. Il grafico mostra chiaramente una gran numero di dimissioni concentrate nei primi 5-10 anni di carriera totale, che si azzerà quasi completamente nei profili più esperti.




Figura 2: Distribuzione delle dimissioni per anni di esperienza lavorativa totale.

4 Modellazione

4.1 Preparazione del Dataset per la Modellazione

Prima dell'addestramento, le feature a varianza zero scoperte in Fase 2 sono state eliminate. Il target è stato mappato in binario (1=Yes, 0=No) e le variabili testuali sono state trasformate. Il dataset è stato diviso in Train (70%) e Test (30%) tramite campionamento stratificato. Infine, si è applicata la Standardizzazione, calcolata come:

$$z = \frac{x - \mu}{\sigma} \quad (1)$$

Questa formula garantisce media nulla e varianza unitaria per tutte le variabili numeriche.

4.2 Regressione Logistica

Il primo modello addestrato è stato un modello lineare: la Regressione Logistica. Trattandosi di un algoritmo basato sui coefficienti, ha beneficiato fortemente della standardizzazione descritta in Equazione 1.

4.3 K-Nearest Neighbors (k-NN)

Il secondo modello è stato il k-NN, un algoritmo basato sul calcolo della distanza tra i valori "vicini". Anche in questo caso, la scalatura dei dati è stata cruciale.

4.4 Random Forest

L'ultimo algoritmo testato è la Random Forest, un modello non lineare basato su alberi decisionali. A differenza dei precedenti, questo modello è molto robusto e non necessita di standardizzazione.

5 Risultati e Discussione

5.1 Confronto dei Modelli

La tabella seguente mette a confronto i tre modelli addestrati sul Test Set.

Modello	Accuracy	Precision	Recall	F1-Score
Regressione Logistica	88.0%	72.5%	40.8%	52.3%
k-NN	83.9%	50.0%	7.0%	12.3%
Random Forest	83.4%	45.5%	14.1%	21.5%

Tabella 1: Confronto delle metriche di valutazione sul Test Set (Classe 'Yes').

5.2 Spiegazione delle Metriche

Per interpretare correttamente la Tabella 1, definiamo le metriche in relazione al nostro obiettivo:

- **Accuracy:** La percentuale di tutte le previsioni corrette (sia i dipendenti rimasti, sia quelli dimessi). A causa dello sbilanciamento del dataset, è una metrica fuorviante.
- **Precision:** Su tutti i dipendenti che il modello ha previsto come dimissionari, quanti si sono licenziati davvero.
- **Recall:** Su tutti i dipendenti che effettivamente si sono licenziati, quanti il modello è riuscito a trovarne. Si tratta della metrica più importante.
- **F1-Score:** È la media tra Precision e Recall, utile per valutare l'equilibrio del modello.

5.3 Approfondimenti sui Modelli

Per concludere la fase di modellazione, abbiamo estratto i *coefficienti* della Regressione Logistica (che ci dicono se una variabile spinge verso il Sì o verso il No) e la *Feature Importance* della Random Forest. Quest'ultima ha decretato che il reddito mensile (*MonthlyIncome*) e l'età (*Age*) sono le variabili più importanti per l'algoritmo.

6 Conclusioni

Il progetto ha dimostrato che le dimissioni aziendali sono prevedibili analizzando variabili chiare come lo stipendio, gli straordinari e l'età. I modelli di Machine Learning hanno faticato a identificare tutti i dimessi (bassa Recall) a causa del forte sbilanciamento delle classi nel dataset iniziale. La Regressione Logistica si è rivelato il modello migliore e più equilibrato per affrontare il problema. Durante lo sviluppo del progetto, l'Intelligenza Artificiale è stata impiegata come strumento di supporto per la formulazione di spunti e ipotesi esplorative all'interno del notebook Colab, nonché per la revisione linguistica e l'ottimizzazione formale di alcune sezioni di questo report.

Riferimenti bibliografici

- [1] Poggi, F. *Slide e materiale didattico del corso "Introduzione alla Data Science e al Pensiero Computazionale"*. Alma Mater Studiorum - Università di Bologna.

- [2] McKinney, W. (2010). *pandas: libreria Python per l'analisi dei dati*.
- [3] Harris, C. R. et al. (2020). *NumPy: calcolo numerico in Python*.
- [4] Hunter, J. D. (2007). *Matplotlib: libreria per la visualizzazione dei dati*.
- [5] Waskom, M. L. (2021). *Seaborn: visualizzazione statistica dei dati*.
- [6] Pedregosa, F. et al. (2011). *Scikit-learn: machine learning in Python*.